



UNIVERSITATEA DIN
BUCUREȘTI

FACULTATEA DE
MATEMATICĂ ȘI
INFORMATICĂ



SPECIALIZAREA INFORMATICĂ

Lucrare de licență

SEGMENTAREA IMAGINILOR

Absolvent

Buciu Theodor Marian

Coordonator științific

Titlul și numele profesorului coordonatorului

București, Februarie 2026

Rezumat

Această lucrare analizează comparativ performanța unor metode clasice și a unor modele Deep Learning pentru segmentarea imaginilor la nivel de obiect. Sunt evaluate două metode clasice, de tip clustering, K-Means și Mean-Shift, precum și două rețele neuronale: U-Net și Slot Attention. Experimentele sunt realizate pe setul de date Tetrominoes din colecția Multi-Object Datasets, utilizând metrica Adjusted Rand Index (ARI) pentru evaluarea calității segmentării.

Rezultatele experimentale arata faptul că metodele clasice, în special Mean-Shift Segmentation, obțin performanțe superioare modelelor de Deep Learning în contextul acestui set de date. În mod surprinzător, arhitectura Slot Attention, atât în varianta supervizată, cât și în cea nesupervizată, înregistrează cele mai scăzute scoruri, în ciuda resurselor de antrenare superioare. De asemenea, performanța modelului U-Net sugerează apariția fenomenului de supraînvățare, indicând o capacitate limitată de generalizare.

Analiza rezultatelor sugerează că simplitatea și dimensiunea redusă a setului de date favorizează metodele clasice de segmentare, în timp ce modelele DeepLearning performează sub așteptari.

Abstract

This paper presents a comparative analysis of classical methods and Deep Learning models for object-level image segmentation. Two classical clustering methods, K-Means and Mean-Shift, as well as two neural network architectures, U-Net and Slot Attention, are evaluated. Experiments are conducted on the Tetrominoes dataset from the Multi-Object Datasets collection, using the Adjusted Rand Index (ARI) to assess segmentation quality. Experimental results indicate that classical methods, particularly Mean-Shift Segmentation, achieve superior performance compared to Deep Learning models on this dataset. Surprisingly, the Slot Attention architecture, both in its supervised and unsupervised variants, records the lowest scores despite having greater training resources. Additionally, the performance of the U-Net model suggests the presence of overfitting. The analysis suggests that the simplicity and small size of the dataset favor classical segmentation methods, while Deep Learning models underperform relative to expectations.

Cuprins

1	Introducere	5
1.1	Motivație	5
1.2	Concepte abordate	5
2	Preliminarii	6
2.1	Metodologie de evaluare	6
2.2	K-means clustering	6
2.3	Mean-Shift Segmentation	6
2.4	U-Net	6
2.5	Slot attention	6
3	Implementare	8
4	Antrenare	9
5	Evaluare	12
6	Concluzii	12
	Referințe	14

1 Introducere

1.1 Motivație

Algoritmi de segmentarea imaginilor au ca scop împărțirea unei imagini în segmente la nivelul pixelilor, creând măști, ce folosesc pentru rezolvarea unor alte probleme, cum ar fi pentru crearea unui sistem de condus autonom sau analiza imaginilor medicale. Această împărțire poate fi semantică unde fiecare pixel primește clasa tipului de conținut pe care o reprezintă sau în funcție de obiect, unde fiecare obiect din imagine are atribuit o clasă, chiar dacă există mai multe obiecte de același tip.

Diferența principală între detectarea de obiecte și segmentarea imaginilor la nivel de obiecte este generarea măștilor. Astfel orice algoritm de segmentare a imaginilor la nivel de obiecte este și un algoritm de detectare a obiectelor, însă reciproca nu este adevărată.

Astfel în această lucrare urmează să analizez mai multe metode de segmentare a imaginilor, în special cele la nivel de obiect, în scopul determinării valabilității algoritmului Slot Attention.

1.2 Concepte abordate

Această lucrare v-a evalua:

- **Metode Clasice** K-means clustering, Mean-Shift Segmentation
- **Metode DeepLearning** U-Net, Slot Attention

2 Preliminarii

2.1 Metodologie de evaluare

Datasetul utilizat este Tetrominoes din "Multi-Object Datasets for PyTorch"[5], scopul acestui dataset este segmentarea unor imagini cu blockuri de tetris, unde fiecare block tetris primește o altă mască. Acest dataset deja conține un split train/test/validate, iar algoritmul de evaluare este "Adjusted Rand Index"(la fel ca în Slot attention[6]).

2.2 K-means clustering

Testarea acestui algoritm va fi făcută cu ajutorul bibliotecă sklearn, ea având o implementare standard. Parametri utilizați în evaluare sunt cei impliciți, mai puțin $K=4$. Se folosesc două reprezentări ale datelor rgb și $\alpha rgbxy$, unde $\alpha \in [1.1, 1.5]$

2.3 Mean-Shift Segmentation

Acest algoritm se găsește din nou în bibliotecă sklearn, astfel și aceasta va fi testat cu argumentele implicite, însă din cauza timpului mare de execuție se va folosi doar reprezentarea rgb .

2.4 U-Net

U-Net[7] este un algoritm convolutional original creat pentru segmentarea bio-medicală. creat pentru segmentarea bio-medical. Această se folosește de "skip connections" pentru a reproduce o imagine de înaltă fidelitate, el fiind la bază doar un autoencoder. Implementarea testată în acest document este "U-net in PyTorch"[1].

2.5 Slot attention

Slot attention[6] este principalul algoritm evaluat și implementat în această lucrare. Modul de funcționare a acestuia este similar cu cel al unui transformer introdus în articolul "Attention is all you need"[8], mai specific este similar cu mecanismului de cross-attention

unde se folosesc tokenuri din două domenii diferite. Cross-attention in mod normal corelează două texte sau tipuri de tokenuri deja existente. Mecanismului de slot attention in schimb este unul competitiv de auto-rafinare unde un embedding, denumit slot în acest context, generat dintr-o distributie de zgomot este împins de un GRU(Gated Recurent Unit)[4] astfel încât să maximizeze atenția acordată unui obiect din imagine. Mai precis mecanismul se bazează pe un backbone, cel mai des CNN, care generează mai multe reprezentări intermediare urmând a fi mapate pozițional folosind ”încapsulări poziționale învățabile”[3], aceste mapări continuă în a fi utilizate drept una dintre intrările mecanismului de atenție.

Definim setul de sloturi $(s_i)_n$ de dimensiune d , unde n_s este numărul maxim de obiecte+1 din imagine, generat inițial dintr-o distribuție gaussiană cu parametri antrenabili. Aceste sloturi trec prin următorul proces de rafinare. Definim matricile W_q și W_k de dimensiune $d \times d$, și considerăm $(x_i)_m, m \geq n$ drept intrările generate din imagine conform procedurii menționat anterior. Astfel generăm matricea de atenție nenormalizată folosind $v_{ij} = \frac{(W_q s_i) \otimes (W_k x_j)}{\sqrt{d}}$, unde raționamentul din spatele formulei este următorul. W_q și W_k sunt două matrici ce produc transformări liniare din spațiile din care fac parte s_i , respectiv x_i către un spațiu comun în care se măsoară corelarea folosind produsul scalar. Această corelare poate fi gândită drept cât de mult răspunde cheia $W_k x_j$ la întrebarea $W_q s_i$. Normalizăm atenția cu ajutorul Softmax: $a_{ij} = \frac{e^{v_{ij}}}{\sum_{k=1}^n e^{v_{kj}}}$ și generăm actualizările $u_i = \sum_j a_{ij} W_v x_j$, unde putem să interpretăm W_v drept matricea ce transformă x_i din spațiul imaginii în spațiul valorilor de update. Aplicăm actualizările $s_i^{(t+1)} = \text{GRU}(s_i^{(t)}, u_i^{(t)}) + \text{MLP}(s_i^{(t)})$, unde (t) reprezintă iterația și MLP este optional. Fiecare slot urmează să fie decodat înapoi în o imagine de dimensiunea inițială, plus un canal α . Astfel canalul α_i devine masca pentru obiectul din slotul s_i după utilizarea funcției Softmax.

3 Implementare

Implementarea modelului de slot attention este făcută în PyTorch, având următoarea configurație:

CnnEncoder

Layer	Type	Kernel/Units	Output Shape
Conv1	Conv2d	$3 \rightarrow 64$, kernel=5	(64, 31, 31)
Activation1	LeakyReLU	-	(64, 31, 31)
Dropout1	Dropout2d(0.2)	-	(64, 31, 31)
Conv2	Conv2d	$64 \rightarrow 64$, kernel=5	(64, 27, 27)
Activation2	LeakyReLU	-	(64, 27, 27)
Dropout2	Dropout2d(0.3)	-	(64, 27, 27)
Conv3	Conv2d	$64 \rightarrow 64$, kernel=5	(64, 23, 23)
Activation3	LeakyReLU	-	(64, 23, 23)

PosEmbedder

Layer	Type	Units	Output Shape
Linear1	Linear	$4 \rightarrow 64$	(64, 23, 23)
Activation	Sigmoid	-	(64, 23, 23)
Linear2	Linear	$64 \rightarrow 64$	(64, 23, 23)
Add to Input	-	-	(64, 23, 23)

SlotAttention

Step	Operation	Units	Output Shape
Preprocessing	LayerNorm + Linear + LeakyReLU (x2)	64	(n_tokens, 64)
Slot Initialization	$\mathcal{N}(\nu, \sigma)$	64	(n_slots, 64)
Iterations	Attention + GRU Evolver	64	(n_slots, 64)

CnnDecoder

Layer	Type	Channels/Units	Output Shape
Spatial Broadcast	-	-	(n_slots, 64+2, 35, 35)
Conv1	Conv2d	66 $\rightarrow$ 32, kernel=5, padding=2	(32, 35, 35)
Activation1	LeakyReLU	-	(32, 35, 35)
Conv2	Conv2d	32 $\rightarrow$ 32, kernel=5, padding=2	(32, 35, 35)
Activation2	LeakyReLU	-	(32, 35, 35)
Conv3	Conv2d	32 $\rightarrow$ 4, kernel=3, padding=1	(4, 35, 35)
Activation3	LeakyReLU	-	(4, 35, 35)

De menționat este faptul că ultimul layer din "CnnDecoder" conține 4 canale, acestea fiind în ordine α, r, g, b și sunt mai departe configurate în funcție de tipul de antrenare.

4 Antrenare

Antrenarea supervizată a fost făcută în toate cazurile cu ajutorul algoritmului maghiar[2] preluat din implementarea facebook. Modelele au fost antrenate pe splitul de antrenare pe următoarele configurații hardware. Optimizatorul folosit este Adamn, iar $lr = 10e - 3$

MODEL	HARDWARE
SlotAttention Unsupervized	Runpod RTX3070 8gb
SlotAttention Supervized	Runpod RTX3080ti 12gb
U-Net	Nvidia Quadro p2000 5gb

Tabela 1: Tabel comparativ modele - ARI




Figura 1: Pierderea a 332 de epoci in antrenarea supervizată a modelului SlotAttention




Figura 2: Pierderea antrenarii nesupravegheate.





Figura 3: Antrenarea U-Net 15 epoci

5 Evaluare



MODEL	ARI
K-Means rgbxy	.857
K-Means rgb 2	.894
MeanshiftSegmentation	.966
SlotAttention Unsupervized	-.086
SlotAttention Supervized	-.006
U-Net	.288

Tabela 2: Tabel comparativ modele - ARI

6 Concluzii

Având în vedere faptul că modelul MeanShiftSegmentation a obținut un scor considerabil de ridicat, se poate deduce ca setul de date utilizat este relativ redus ca dimensiune și prezintă un nivel scăzut de complexitate. În mod surprinzător, modelele bazate pe tehnici de Deep Learning au înregistrat cele mai slabe performanțe, iar arhitectura Slot Attention a obținut cele mai reduse scoruri, în ciuda faptului că a beneficiat de cele mai ample resurse de antrenare. Performanța modelului U-Net pe datele de testare sugerează existența overfittingului. Cu toate acestea rezultatele originale ale studiului ce a introdus acest mecanism[6], duc către posibilitate de a nu fi antrenat corect arhitectura. Posibile

viitoare rafinari includ dar nu sunt limitate la schimbarea learning rateului sau a optimizatorului. Utilizarea unui backbone deja existent. Și chiar si utilizarea unui model de difusie.

Referințe

- [1] Mateusz Buda, Ashirbani Saha și Maciej A. Mazurowski, „Association of genomic subtypes of lower-grade gliomas with shape features automatically extracted by a deep learning algorithm”, în *Computers in Biology and Medicine* 109 (2019), pp. 218–225, ISSN: 0010-4825, DOI: <https://doi.org/10.1016/j.combiomed.2019.05.002>, URL: <https://www.sciencedirect.com/science/article/pii/S0010482519301520>.
- [2] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov și Sergey Zagoruyko, „End-to-End Object Detection with Transformers”, în *CoRR* abs/2005.12872 (2020), arXiv: [2005.12872](https://arxiv.org/abs/2005.12872), URL: <https://arxiv.org/abs/2005.12872>.
- [3] Md Abtahi Majeed Chowdhury, Md Rifat Ur Rahman și Akil Ahmad Taki, *LOOPE: Learnable Optimal Patch Order in Positional Embeddings for Vision Transformers*, 2025, arXiv: [2504.14386](https://arxiv.org/abs/2504.14386) [cs.CV], URL: <https://arxiv.org/abs/2504.14386>.
- [4] Junyoung Chung, Çağlar Gülçehre, KyungHyun Cho și Yoshua Bengio, „Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling”, în *CoRR* abs/1412.3555 (2014), arXiv: [1412.3555](http://arxiv.org/abs/1412.3555), URL: <http://arxiv.org/abs/1412.3555>.
- [5] Rishabh Kabra, Chris Burgess, Loic Matthey, Raphael Lopez Kaufman, Klaus Greff, Malcolm Reynolds și Alexander Lerchner, *Multi-Object Datasets*, <https://github.com/JohannesThe> 2019.
- [6] Francesco Locatello, Dirk Weissenborn, Thomas Unterthiner, Aravindh Mahendran, Georg Heigold, Jakob Uszkoreit, Alexey Dosovitskiy și Thomas Kipf, „Object-Centric Learning with Slot Attention”, în *arXiv preprint arXiv:2006.15055* (2020).
- [7] Olaf Ronneberger, Philipp Fischer și Thomas Brox, „U-Net: Convolutional Networks for Biomedical Image Segmentation”, în *CoRR* abs/1505.04597 (2015), arXiv: [1505.04597](http://arxiv.org/abs/1505.04597), URL: <http://arxiv.org/abs/1505.04597>.

- [8] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser și Illia Polosukhin, „Attention is all you need”, în *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 5998–6008.